

Análise - A New Golden Age for Computer Architecture

Gustavo Henrique Stahl Müller

¹Ciência da Computação / UNIVALI - Itajaí

gustavo.henrique2015@yahoo.com.br

Abstract. *This meta-paper describes an undergraduate's point of view and understanding of A New Golden Age for Computer Architecture, an article written by John L. Hennessy and David A. Patterson. Consequentially, this paper should not be used as reference in future studies or taken seriously in the academic world.*

Abstract. *Esse artigo descreve o ponto de vista e entendimento de um graduando sobre o artigo A New Golden Age for Computer Architecture, escrito por John L. Hennessy e David A. Patterson. Consequentemente, esse artigo não deve ser usado como referência em estudos futuros ou ser levado a sério no mundo acadêmico.*

1 Introdução

Esse artigo contém uma visão geral sobre todas as partes descritas no artigo A New Golden Age for Computer Architecture.

2 Conceito

O artigo, em suas 13 páginas, disserta sobre conceitos relacionados à Arquitetura e Organização de Computadores e suas trajetórias ao longo dos anos, como por exemplo:

- Métodos de aperfeiçoamento de desempenho usados no passado;
- Limitações físicas relacionadas ao desenvolvimento de circuitos integrados nos dias de hoje;
- Ascensão do modelo RISC, decadência do modelo CISC e suas causas;
- Técnicas de desempenho que poderão ser utilizadas no futuro;

3 Início

3.1 Motivação

Na década de 1960, a IBM possuía 4 linhas de computadores incompatíveis, todas com suas próprias características. Isso gerou a ideia de criar um ISA (Instruction Set Architecture) que fosse único e que combinava todos os fatores das 4 linhas, como a alta velocidade dos computadores que usavam uma largura de banda de 64 bits e o baixo custo de computadores que usavam somente 8 bits. O maior desafio para criar tal ISA era a unidade de controle.

3.2 Inovação

Então, Maurice Wilkes propôs uma ideia que simplificaria as unidades de controle: Ao invés de usar uma unidade hard-wired que, através de lógica combinatória, gerasse

o caminho correto para a instrução, a unidade de controle seria uma matriz feita de micro-instruções, sendo que um conjunto de micro-instruções corresponderia à uma instrução convencional. Isso significa que a unidade de controle não precisava ser criada através de lógica combinatória, mas sim através de memória.

3.3 Resultados

Esse tipo de organização ficou conhecido como microprogramação. Como implementar memória é mais barato que implementar portas lógicas, unidades de controle feitas por microprogramação eram mais baratas que unidades de controle hard-wired. A IBM previu que essa ISA iria dominar o mercado no futuro, e acertaram em cheio.

4 Criação de ISA's mais simples

4.1 Circuitos Integrados

Quando computadores começaram a usar circuitos integrados, o tamanho das unidades de controle se tornou muito menor, o que significa que se tornou possível fazer memórias de controle que ocupavam o mesmo espaço que as antigas mas que possuíam uma capacidade de armazenamento muito maior. Essa capacidade de memória maior permitiu a criação de ISA's mais complexos. Alguns fabricantes decidiram expandir o conceito de microprogramação, permitindo que seus clientes adicionassem funcionalidades adicionais na unidade de controle. Isso ficou conhecido como WCS (Writable Control Store).

4.2 CISC e RISC

A década de 80 teve muitas investigações ao redor de arquiteturas CISC, permitidas pelo maior tamanho das unidades de controle organizadas em microprogramação. John Cocke e seus colegas desenvolveram ISA's mais simples para microcomputadores. Eles perceberam que, com um conjunto de instruções mais simples, programas rodavam até 20% mais rápido. Não só isso, mas Emmer e Clark descobriram que na arquitetura VAX, 20% das suas instruções representavam 60% do microcódigo, e só estavam em funcionamento durante 0.2% do tempo de execução. As arquiteturas usadas em microcomputadores eram tão complexas que os seus bugs precisavam ser consertados pelo próprio cliente. Isso inspirou Cocke a trabalhar em arquiteturas reduzidas (RISC - Reduced instruction set computers).

4.3 Resultados

Engenheiros notaram que programas feitos para arquiteturas CISC executavam 75% das instruções que um programa RISC executava, mas em contrapartida, demoravam 5 a 6 vezes mais ciclos de relógio por instrução, resultando em arquiteturas RISC sendo (aproximadamente) 4x mais rápidas. Esse tipo de cálculo não fazia parte da arquitetura de computadores da época, e foi introduzido com o livro *Computer Architecture: A Quantitative Approach* em 1989. Através dele, se obteve uma abordagem quantitativa e exata em questões relacionadas à performance, ao invés de uma abordagem intuitiva e empírica.

5 VLIW, EPIC, Itanium

5.1 Nova Motivação

A próxima inovação dos ISA's pretendia ultrapassar tanto RISC quanto CISC. VLIW (very long instruction word) e EPIC (explicitly parallel instruction computer), assim como a arquitetura RISC, pretendiam deslocar o trabalho do hardware para os compiladores.

5.2 Execução

Hewlett e Intel trabalharam juntos para projetar um processador de 64 bits baseada nas ideias EPIC para substituir a arquitetura x86 de 32 bits. Esse projeto se chamou Itanium. Segundo Donald Knuth, mesmo que o conceito EPIC fosse fantástico, era praticamente impossível criar os compiladores necessários para o seu funcionamento.

5.3 Resultados

O mercado ficou impaciente com o projeto Itanium. Consequentemente, o sucessor do x86 de 32 bits foi uma versão igual de 64 bits, ao invés do processador EPIC.

6 RISC vs. CISC na era PC e pós-PC

6.1 Popularidade do x86

AMD e Intel exportaram cerca de 350 milhões de processadores x86 no final de 2011. Com essa popularidade, o mercado de PC's se importava com somente um ISA, então os desenvolvedores só se preocupavam em fazer seu software ser binariamente compatível com a arquitetura x86. Com uma base de software grande, alta performance e preços baixos, a arquitetura x86 dominou a área de computadores pessoais e servers pequenos em meados de 2000.

6.2 Era pós-PC

A Apple ajudou a iniciar a era pós-PC com o iPhone em 2007. Ao invés de comprar microprocessadores, eles construíram seus próprios sistemas, usando designs de outras empresas (processadores RISC da ARM). Como desenvolvedores de sistemas móveis necessitavam de baixo consumo de energia e baixo aquecimento, processadores CISC não eram boas alternativas, pois não atendiam essas necessidades devido ao maior número de transistores. E também, com a chegada da Internet das Coisas, aumentou a demanda por processadores simples, pequenos, de baixo custo e consumo de energia. Hoje em dia, 99% dos processadores 32-bit e 64-bit são RISC.

6.3 Conclusão

Faz décadas desde que um novo ISA CISC foi criado. Mesmo que processadores CISC tenham dominado o mercado no passado, RISC sai ganhando na era pós-PC que vivemos hoje.

7 Desafios modernos para arquitetura de processadores

7.1 Tecnologia MOS

Embora que a sessão passada tenha focado nos designs de ISA's, muitos arquitetos de computadores não criam conjuntos de instruções novos, mas sim implementam algum já existente. Desde a década de 1970, a tecnologia padrão para a implementação de circuitos integrados foi MOS (Metal Oxide Semiconductor), com evoluções ao longo dos anos (nMOS e CMOS). Essa evolução é o que permitiu que arquitetos de computadores fizessem melhorias mais agressivas para aprimorar o desempenho de ISA's.

7.2 Lei de Moore

Moore previu em 1965 que a quantidade de transistores em um circuito dobraria a cada ano. Em 1975, ele reajustou, prevendo um dobramento a cada dois anos. Eventualmente, essa previsão ficou conhecida como Lei de Moore.

8 Fim da Lei de Moore e Escala de Dennard

8.1 Início

A Lei de Moore se sustentou por muitos anos, mas ela começou a desacelerar em meados de 2000. Em 2018, o número de transistores previstos pela lei foi aproximadamente 15 vezes maior que o número de transistores reais. Acompanhando a Lei de Moore, existia a Escala de Dennard, que afirmava que a medida que transistores ficavam menores, o consumo por transistor diminuía, logo, era possível colocar mais transistores sem fazer com que o circuito consumisse mais energia. Em 2012, a Escala de Dennard já havia sido invalidada e esquecida.

8.2 ILP

Entre 1986 e 2002, o principal método para aprimorar o desempenho de um computador era ILP (instruction level parallelism). Esse método, em conjunto da evolução dos transistores, resultava em um ganho de performance anual de aproximadamente 50%. O fim da Escala de Dennard significou que os arquitetos precisaram procurar outras maneiras de usufruir de paralelismo.

8.3 Multicore

O surgimento da tecnologia multicore deslocou a responsabilidade de identificar paralelismo para o programador e não para o hardware. Multicore não resolve o problema de energia computacional relacionada ao fim da Escala de Dennard, já que cada core consome energia independentemente se contribui efetivamente à computação em

questão ou não. Isso também significa que processadores consomem mais energia por core, e consequentemente dissipam mais calor. Logo, processadores multicore são limitados pelo TDP (thermal dissipation power), que é a quantidade máxima de calor que o sistema padrão de resfriamento consegue retirar.

8.4 Silício Escuro

Esse limite chamado TDP levou à era do silício escuro, onde processadores reduzem o clock rate e desligam cores inativos para evitar sobreaquecimento.

8.5 Conclusão

Com o fim da Escala de Dennard e com a Lei de Moore não sendo mais verdadeira, é necessário novas abordagens à arquitetura de computadores para atingir o mesmo ganho de performance que era alcançado antigamente.

9 Segurança Ignorada

9.1 Início

Na década de 70, arquitetos de computadores deram muita atenção para a segurança de computadores. Eles acreditavam que a maioria das brechas e bugs estariam no software, mas que uma base arquitetural também iria ajudar. Essas funcionalidades foram ignoradas por softwares benignos, pois custavam recursos para serem implementadas.

9.2 Resultados

Infelizmente, nosso foco em desempenho significou que essas funcionalidades não receberam a devida atenção, e isso resultou em softwares grandes que ainda possuem problemas de segurança.

10 Oportunidades Futuras em Arquitetura de Computadores

10.1 Início

Os processadores de uso geral com suas ineficiências, como técnicas ILP, multicore, combinadas com o fim da Lei de Moore e Escala de Dennard, levam os arquitetos de computadores a acreditar que processadores de uso geral estão chegando em seus limites em termos de desempenho. Quais outros métodos de ganho de desempenho podem ser usados?

10.2 Linguagens Interpretadas

Softwares modernos fazem uso extensivo de linguagens de programação interpretadas, com tipagem dinâmica e coleta de lixo automática. Essas linguagens, infelizmente, são extremamente ineficientes. Ao transferir um código de multiplicação de matriz de Python para C, a performance aumenta em 47 vezes, após fazer uso de caches, paralelismo e operações SIMD à nível de hardware.

10.3 Arquiteturas Específicas à Domínios (DSA)

Uma abordagem mais ligada ao hardware à questões de performance é a criação de arquiteturas específicas à um domínio, que podem oferecer mais desempenho à tarefas específicas e predeterminadas, mas também podem ser programadas pelos usuários. Isso pode ser chamado de aceleração de hardware, pois é usado um hardware específico para realizar certa ação, ao invés de um processador de uso geral. Esse desempenho adicional vem de otimizações como SIMD, uso eficiente de caches, maior controle de tamanho de palavra das unidades de memória, entre outros.

10.4 Linguagens Específicas à Domínios (DSL)

Tirar proveito dessas características seria difícil com linguagens como Java ou Python, logo, são criadas linguagens de programação que dão suporte às arquiteturas. O desafio ao usar DSL's é deixar ela independente o suficiente da arquitetura para que ela possa ser reusada entre vários DSA's similares, permitindo o mapeamento correto entre as instruções da linguagem com o próprio hardware.

11 Sumário

Por fim, descobrimos duas abordagens diferentes para aumentar o desempenho computacional:

- Otimizar linguagens de alto nível que são tipicamente interpretadas;
- Criação de DSA's e DSL's que são mais eficientes em certas aplicações quando comparadas à processadores de uso geral;

O fim da Lei de Moore e Escala de Dennard não são problemas que devem ser resolvidos, e sim reconhecidos e gerenciados.

References

- [1] John L. Hennessy e David A. Patterson. *A New Golden Age for Computer Architecture*. February 2019.