

SISTEMA DE RACIOCÍNIO BASEADO EM CASOS PARA REALIZAR A PREDIÇÃO DE ACIDENTES VASCULARES CEREBRAIS (AVC)

Gustavo Henrique Stahl Müller

Luan Luiz Gambeta

Paulo Henrique Rohling

INTRODUÇÃO

De acordo com a Organização Mundial da Saúde (OMS), o AVC é a segunda causa de morte mais popular no mundo, representando aproximadamente 11% do total de mortes (OMS, 2020).

O objetivo deste trabalho é desenvolver um sistema de raciocínio baseado em casos para indicar a possibilidade de uma pessoa vir a sofrer um AVC de acordo com a similaridade entre o seu prontuário médico e os prontuários médicos de pacientes cadastrados na base de dados escolhida.

AQUISIÇÃO DE CASOS

Todos os os dados referentes aos prontuários médicos de pacientes foram obtidos do dataset “*Stroke Prediction Dataset*”, publicado por Soriano (2021) na plataforma Kaggle.

O dataset está disponível no formato CSV e possui 5110 registros, que contém dados de gênero (masculino, feminino ou outro), idade, se já foi casado, ocorrência de algum problema de hipertensão, ocorrência de algum problema cardíaco, tipo de emprego (privado, autônomo, menor de idade, serviço governamental, nunca trabalhou), tipo de residência (urbano ou rural), nível médio de glicose, índice de massa corporal, prática de tabagismo (fumante, não fumante, já foi fumante, desconhecido), ocorrência de AVC e, por último, um identificador número para o registro.

REPRESENTAÇÃO DE CASOS

O dataset selecionado é bem direcionado para o problema proposto, de forma que o filtro de atributos feito para definir a nossa representação de caso é bem simples. Os dados

de estado civil, tipo de emprego e tipo de residência foram descartados para que sejam mantidos apenas os atributos medicamente relevantes.

DATASET ORIGINAL

id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
9046	Male	67	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
51676	Female	61	0	0	Yes	Self-employed	Rural	202.21	N/A	never smoked	1
31112	Male	80	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
60182	Female	49	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
1665	Female	79	1	0	Yes	Self-employed	Rural	174.12	24	never smoked	1
56669	Male	81	0	0	Yes	Private	Urban	186.21	29	formerly smoked	1
53882	Male	74	1	1	Yes	Private	Rural	70.09	27.4	never smoked	1
10434	Female	69	0	0	No	Private	Urban	94.39	22.8	never smoked	1
27419	Female	59	0	0	Yes	Private	Rural	76.15	N/A	Unknown	1
60491	Female	78	0	0	Yes	Private	Urban	58.57	24.2	Unknown	1
12109	Female	81	1	0	Yes	Private	Rural	80.43	29.7	never smoked	1
12095	Female	61	0	1	Yes	Govt_Job	Rural	120.46	36.8	smokes	1
12175	Female	54	0	0	Yes	Private	Urban	104.51	27.3	smokes	1
8213	Male	78	0	1	Yes	Private	Urban	219.84	N/A	Unknown	1
5317	Female	79	0	1	Yes	Private	Urban	214.09	28.2	never smoked	1
58202	Female	50	1	0	Yes	Self-employed	Rural	167.41	30.9	never smoked	1
56112	Male	64	0	1	Yes	Private	Urban	191.61	37.5	smokes	1
34120	Male	75	1	0	Yes	Private	Urban	221.29	25.8	smokes	1
27458	Female	60	0	0	No	Private	Urban	89.22	37.8	never smoked	1
25226	Male	57	0	1	No	Govt_Job	Urban	217.08	N/A	Unknown	1
70630	Female	71	0	0	Yes	Govt_Job	Rural	193.94	22.4	smokes	1
13861	Female	52	1	0	Yes	Self-employed	Urban	233.29	48.9	never smoked	1
68794	Female	79	0	0	Yes	Self-employed	Urban	228.7	26.6	never smoked	1
64778	Male	82	0	1	Yes	Private	Rural	208.3	32.5	Unknown	1
4219	Male	71	0	0	Yes	Private	Urban	102.87	27.2	formerly smoked	1
70822	Male	80	0	0	Yes	Self-employed	Rural	104.12	23.5	never smoked	1
38047	Female	65	0	0	Yes	Private	Rural	100.98	28.2	formerly smoked	1
61843	Male	58	0	0	Yes	Private	Rural	189.84	N/A	Unknown	1

EXEMPLO DE CASO

CASO	
Gênero	Masculino
Idade	67 anos
Histórico de hipertensão	Não
Histórico de doença cardíaca	Sim
Nível médio de glicose	228,69 mg/dL
IMC	36,60
Prática de Tabagismo	Ex-fumante
Ocorrência de AVC	Sim

BASE DE DADOS

id [PK] integer	gender integer	age integer	hypertension boolean	heart_disease boolean	avg_glucose_level numeric (5,2)	bmi numeric (5,2)	smoking_status integer	stroke boolean
1	0	67	false	true	228.69	36.60	2	true
2	1	61	false	false	202.21	[null]	1	true
3	0	80	false	true	105.92	32.50	1	true
4	1	49	false	false	171.23	34.40	3	true
5	1	79	true	false	174.12	24.00	1	true
6	0	81	false	false	186.21	29.00	2	true
7	0	74	true	true	70.09	27.40	1	true
8	1	69	false	false	94.39	22.80	1	true
9	1	59	false	false	76.15	[null]	0	true
10	1	78	false	false	58.57	24.20	0	true
11	1	81	true	false	80.43	29.70	1	true
12	1	61	false	true	120.46	36.80	3	true
13	1	54	false	false	104.51	27.30	3	true
14	0	78	false	true	219.84	[null]	0	true
15	1	79	false	true	214.09	28.20	1	true
16	1	50	true	false	167.41	30.90	1	true
17	0	64	false	true	191.61	37.50	3	true

INDEXAÇÃO

Segundo Simm (2020), a maior causa de AVCs é a hipertensão arterial. Por este motivo, foi atribuído peso máximo para o atributo Histórico de Hipertensão. Sedentarismo, diabetes, doenças cardíacas e tabagismo são outros fatores que podem afetar a circulação, de forma que os atributos correspondentes a estas doenças devem ser mais relevantes do que gênero e idade.

No entanto, há mais chances de ocorrer um AVC em pessoas mais idosas, uma vez que o sistema circulatório começa a se debilitar, logo, seu peso é superior ao do atributo gênero.

Índice	Peso
Gênero	0.2
Idade	0.5
Histórico de hipertensão	1.0
Histórico de doença cardíaca	0.8
Nível médio de glicose	0.8
IMC	0.8
Prática de Tabagismo	0.8

RECUPERAÇÃO

CÁLCULO DE SIMILARIDADE

Para o cálculo de similaridade entre os casos, serão utilizados três métodos diferentes, a depender do tipo de valor de cada atributo.

Igualdade: Para os atributos de gênero, histórico de hipertensão e histórico de doença, a comparação é feita por igualdade, ou seja, é igual (1) ou não é igual (0).

Similaridade de tipos numéricos: Para os atributos de idade, nível médio de glicose e IMC, a comparação é feita dividindo a diferença absoluta entre os dois valores pelo intervalo de valores do atributo, assim como mostra a equação abaixo.

$$Sim(A, B) = 1 - \left(\frac{|B - A|}{MAX - MIN} \right)$$

Similaridade de tipos simbólicos: Para o atributo de prática de tabagismo, foram pré-definidos valores de similaridade com base nas possíveis combinações. Os valores são mostrados na tabela abaixo. Nota-se que quando o valor é desconhecido, atribui-se similaridade máxima, para que este atributo seja relevado.

	Desconhecido	Não-fumante	Ex-fumante	Fumante
Desconhecido	1.0	1.0	1.0	1.0
Não-fumante	1.0	1.0	0.0	0.0
Ex-fumante	1.0	0.0	1.0	0.7
Fumante	1.0	0.0	0.7	1.0

EXEMPLO DE CÁLCULO DE SIMILARIDADE

CASO 1			CASO 2	
Gênero	Masculino		Gênero	Feminino
Idade	67 anos		Idade	61 anos
Histórico de hipertensão	Não		Histórico de hipertensão	Não
Histórico de doença cardíaca	Sim		Histórico de doença cardíaca	Não
Nível médio de glicose	228,69 mg/dL		Nível médio de glicose	202,21 mg/dL
IMC	36,60		IMC	32,50
Prática de Tabagismo	Ex-fumante		Prática de Tabagismo	Não-fumante

SIMILARIDADE			
Atributo	Peso	Cálculo	Resultado
Gênero	0.2	0.2×0.0	0.0
Idade	0.5	$0.5 \times [1 - (67 - 61 / 82 - 1)]$	0.46
Histórico de hipertensão	1.0	1.0×1.0	1.0
Histórico de doença cardíaca	0.8	0.8×0.0	0.0
Nível médio de glicose	0.8	$0.8 \times [1 - (228.69 - 202.21 / 271,74 - 55,12)]'$	0.7
IMC	0.8	$0.8 \times [1 - (36.6 - 32.5 / 97.6 - 10.3)]$	0.76
Prática de Tabagismo	0.8	0.8×0.0	0.0
RESULTADO FINAL		$\frac{(0.0 + 0.46 + 1.0 + 0.0 + 0.7 + 0.76 + 0.0)}{0.2 + 0.5 + 1.0 + 0.8 + 0.8 + 0.8 + 0.8}$	0,59

REFERÊNCIAS

SIMM, R. **7 Principais Causas de AVC**. 2020. Disponível em:
<<https://www.santapaula.com.br/blog/voce-sabia-que-ha-7-principais-causas-de-avc/>>.
Acesso em: 22 mai. 2022.

SORIANO, F. **Stroke Predition Dataset**. Disponível em:
<<https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>>. Acesso em: 18
mai. 2022.

WHO. **The Top 10 Causes of Death**. 2020. Disponível em:
<<https://www.who.int/news-room/fact-sheets/detail/the-top-10-causes-of-death>>. Acesso em:
20 mai. 2022.