



UNIVALI

Universidade do Vale do Itajaí
Escola do Mar, Ciência e Tecnologia - EMCT
Ciência da Computação

CLASSIFICAÇÃO DE VINHOS UTILIZANDO REDES NEURAIS

Gustavo Henrique Stahl Müller
Luan Luiz Gambeta
Paulo Henrique Rohling



Problema

Identificar a **vinícola de origem** de um vinho com base nos dados de uma **análise química** do mesmo.

- **Problema de classificação;**
- **Problema de reconhecimento de padrões.**



Dataset

O dataset escolhido possui **178** registros com os seguintes atributos:

Álcool, Ácido málico, Cinzas, Alcalinidade das cinzas, Magnésio, Fenóis totais, Flavonóides, Fenóis não flavonóides, Proantocianidinas, Intensidade da cor, Matiz, OD280/OD315 e Prolina.

# Alcohol	# Malic_Acid	# Ash	# Ash_Alcali...	# Magnesium	# Total_Phe...	# Flavonoids	# Nonflavan...	# Proanthoc...	# Color_Inte...	# Hue	# OD280	# Proline
14.23	1.71	2.43	15.6	127	2.8	3.06	0.28	2.29	5.64	1.04	3.92	1065
13.2	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.4	1050
13.16	2.36	2.67	18.6	101	2.8	3.24	0.3	2.81	5.68	1.03	3.17	1185
14.37	1.95	2.5	16.8	113	3.85	3.49	0.24	2.18	7.8	0.86	3.45	1480
13.24	2.59	2.87	21	118	2.8	2.69	0.39	1.82	4.32	1.04	2.93	735
14.2	1.76	2.45	15.2	112	3.27	3.39	0.34	1.97	6.75	1.05	2.85	1450
14.39	1.87	2.45	14.6	96	2.5	2.52	0.3	1.98	5.25	1.02	3.58	1290
14.06	2.15	2.61	17.6	121	2.6	2.51	0.31	1.25	5.05	1.06	3.58	1295
14.83	1.64	2.17	14	97	2.8	2.98	0.29	1.98	5.2	1.08	2.85	1045

Fonte: <https://www.kaggle.com/datasets/harrywang/wine-dataset-for-clustering>

Dataset

A própria **documentação do Neuroph** fornece este dataset com os dados já **normalizados**.

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
0.747	0.229	0.77	0.454	0.402	0.679	0.555	0.453	0.426	0.275	0.626	0.78	0.454	1	0	0
0.274	0.281	0.433	0.536	0.163	0.559	0.487	0.453	0.297	0.126	0.309	0.736	0.071	0	1	0
0.713	0.184	0.476	0.299	0.522	0.559	0.54	0.151	0.382	0.39	0.358	0.707	0.558	1	0	0
0.861	0.233	0.727	0.485	0.543	0.628	0.591	0.377	0.492	0.42	0.48	0.505	0.715	1	0	0
0.353	0.077	0.428	0.433	0.185	0.869	0.582	0.113	0.461	0.27	0.602	0.586	0.101	0	1	0
0.647	0.563	0.444	0.459	0.196	0.221	0.03	0.849	0.148	0.377	0.268	0.201	0.215	0	0	1
0.392	0.334	0.433	0.536	0.196	0.541	0.407	0.245	0.256	0.061	0.341	0.553	0.034	0	1	0
0.437	0.156	0.481	0.521	0.109	0.138	0.236	0.849	0.382	0.151	0.39	0.289	0.155	0	1	0

$$X_n = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Fonte: <http://neuroph.sourceforge.net/tutorials/wines1/download/NormalizedDataSet.txt>

Divisão Treinamento/Teste


Para realizar a divisão do dataset em dois conjuntos (Treinamento e Teste), utilizamos a biblioteca **scikit-learn**, que se baseia em **seleção por aleatoriedade**.

```
>>> X_train, X_test = train_test_split(x, test_size=0.3, random_state=42)
```

Fonte: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html


Divisão do Dataset

Teste
30,0%




Divisão Treinamento/Teste

Divisão do Dataset



Representatividade no Treinamento

Divisão do Dataset



Representatividade no Teste

Rede Neural



Para a criação da rede neural, utilizamos o framework **Neuroph**, bem como o dataset disponibilizado na sua documentação;

A rede neural é uma **Multi Layer Perceptron** com algoritmo de aprendizado **Backpropagation**;

O conjunto de dados possui **13 entradas** e **3 saídas**. De início, utilizamos apenas **uma camada** com **17 neurônios**.

Rede Neural

New Neural Network

Etapas

1. Set neural network name and type
- 2.

Setting Multi Layer Perceptron's parameters

Input neurons

Hidden neurons (space delimited for layers)

Output neurons

☒ Use Bias Neurons


☐ Connect input to output neurons

Transfer function

Learning rule

< Voltar Próximo > Finalizar Cancelar Ajuda


Rede Neural



Treinamento 1

Para um primeiro teste, treinamos a rede neural com os parâmetros padrões que o Neuroph sugeriu, apenas definindo o limite de iterações para 100.

- Erro máximo: **0.01**
- Limite de iterações: **100**
- Taxa de aprendizado: **0.2**



The screenshot shows the Neuroph training configuration window with the following settings:


- Stopping Criteria:**
 - Max Error: 0.01
 - ☒ Limit Max Iterations: 100
- Learning Parametars:**
 - Learning Rate: 0.2
 - Momentum: 0.7
- Crossvalidation:**
 - ☐ Use Crossvalidation
 - Number of folds: 4
 - ☐ Save all trained networks
- Options:**
 - ☒ Display Error Graph (unchecked for faster learning)
 - ☐ Use Deep Netts Deep Learning Engine

Resultados do Treinamento 1

Nota-se que o treinamento parou porque atingiu o máximo de **100 iterações**.

Apesar disso, a taxa de erro se manteve baixa ao aplicar o conjunto de testes.


- Taxa de erro: **0.010663482473875009**



Treinamento 2

Neste segundo teste, investigou-se a possibilidade de atingir a taxa de erro máxima determinada anteriormente em menos iterações. Para isso, a taxa de aprendizado foi aumentada.

- Erro máximo: **0.01**
- Limite de iterações: **100**
- Taxa de aprendizado: **0.5**




The image shows a configuration window for a neural network training process, divided into four sections:

- Stopping Criteria:**
 - Max Error: 0.01
 - ☒ Limit Max Iterations: 100
- Learning Parameters:**
 - Learning Rate: 0.5
 - Momentum: 0.7
- Crossvalidation:**
 - ☐ Use Crossvalidation
 - Number of folds: 4
 - ☐ Save all trained networks
- Options:**
 - ☒ Display Error Graph (unchecked for faster learning)
 - ☐ Use Deep Net's Deep Learning Engine

Resultados do Treinamento 2

Desta vez, o treinamento parou antes do marco das 100 iterações, pois atingiu a taxa de erro máxima determinada.


- Taxa de erro: **0.009796663955373456**



Treinamento 3

Neste terceiro teste, investigou-se a possibilidade de **reduzir** a taxa de erro máxima.

- Erro máximo: **0.0001**
- Limite de iterações: **100**
- Taxa de aprendizado: **0.5**



The screenshot displays a configuration window for a neural network training process, organized into four sections:


- Stopping Criteria:**
 - Max Error: 0.0001
 - ☒ Limit Max Iterations: 100
- Learning Parameters:**
 - Learning Rate: 0.5
 - Momentum: 0.7
- Crossvalidation:**
 - ☐ Use Crossvalidation
 - Number of folds: 4
 - ☐ Save all trained networks
- Options:**
 - ☒ Display Error Graph (unchecked for faster learning)
 - ☐ Use Deep Netts Deep Learning Engine

Resultados do Treinamento 3

O treinamento novamente parou porque atingiu o máximo de **100 iterações**.

Apesar disso, nota-se que a taxa de erro caiu consideravelmente, sendo esta a taxa de erro mais baixa entre os três treinamentos.

- Taxa de erro: **0.001893700241934095**



Conclusão

Teste	Taxa de aprendizado	Iterações	Erro médio
1	0.2	100	~0.0106
2	0.5	45	~0.0097
3	0.5	100	~0.0018

Referências

NEUROPH. **Classification problem example using Neuroph framework**. 2022.

Disponível em:

<<http://neuroph.sourceforge.net/tutorials/wines1/download/NormalizedDataSet.txt/>>. Acesso em: 3 jul. 2022.

UCI. **Wine Data Set**. Disponível em: <<http://archive.ics.uci.edu/ml/datasets/Wine>>. Acesso em: 3 jul. 2022.

WANG, H. **Wine Dataset for Clustering**. 2020. Disponível em: <<https://www.kaggle.com/datasets/harrywang/wine-dataset-for-clustering/>>. Acesso em: 3 jul. 2022.



UNIVALI

Universidade do Vale do Itajaí
Escola do Mar, Ciência e Tecnologia - EMCT
Ciência da Computação

CLASSIFICAÇÃO DE VINHOS UTILIZANDO REDES NEURAIS

Gustavo Henrique Stahl Müller
Luan Luiz Gambeta
Paulo Henrique Rohling

