



UNIVALI

Universidade do Vale do Itajaí  
Escola do Mar, Ciência e Tecnologia - EMCT  
Ciência da Computação

---

# PROCESSO DE KDD APLICADO EM SINTOMAS DE DOENÇAS CRÔNICAS

---

Caio Gonzaga Bernils  
Gustavo Henrique Stahl Müller  
Paulo Henrique Rohling

---



# Sumário


- Apresentação do tema
- Detalhamento do dataset
- Transformações iniciais
- Análise exploratória
- Pré-processamento
- Associação (Apriori)
- Resultados

# Apresentação do tema

**Doenças crônicas** são doenças cujo **tratamento é longo** (pelo menos 3 meses) e necessitam de **cuidados médicos constantes**.

Exemplos: asma, mal de Parkinson, diabetes e osteoporose.

**Flaredown** é um aplicativo desenvolvido para ajudar no **gerenciamento de sintomas, medicamentos e refeições** de pessoas que sofrem de doenças crônicas.



# Apresentação do tema

Os usuários deste aplicativo registram, **diariamente**, a gravidade dos sintomas, as doses de medicamentos ingeridos e outros gatilhos relevantes, como alimentos e níveis de estresse.

Estes registros diários são chamados de **rastreáveis** e o próprio usuário personaliza o seu conjunto de **sintomas, tratamentos e condições** com o qual vai trabalhar.



# Detalhamento do dataset



O dataset do Flaredown possui **7.976.223** registros de **42.283** usuários diferentes, onde cada registro possui **9** atributos.

| dataset.head(10) |                                  |          |        |         |              |              |                |                                                   |                 |
|------------------|----------------------------------|----------|--------|---------|--------------|--------------|----------------|---------------------------------------------------|-----------------|
|                  | user_id                          | age      | sex    | country | checkin_date | trackable_id | trackable_type | trackable_name                                    | trackable_value |
| 0                | QEVuQwEABIEzkh7fsBBjEe26RyIVcg== | NaN      | NaN    | NaN     | 2015-11-26   | 1069         | Condition      | Ulcerative colitis                                | 0               |
| 1                | QEVuQwEAWRNGnuTRqXG2996KSkTIEw== | 32.00000 | male   | US      | 2015-11-26   | 1069         | Condition      | Ulcerative colitis                                | 0               |
| 2                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3168         | Condition      | pain in left upper arm felt like i was getting... | 4               |
| 3                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3169         | Condition      | hip pain when gettin up                           | 3               |
| 4                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3170         | Condition      | pain in hand joints                               | 4               |
| 5                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3171         | Condition      | numbness in right hand                            | 2               |
| 6                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 1356         | Condition      | Headache                                          | 2               |
| 7                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3172         | Condition      | pain in left ankle                                | 1               |
| 8                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3173         | Condition      | pain in left leg                                  | 1               |
| 9                | QEVuQwEA+WkNxtq/qkHvN2YmTBBDqg== | 2.00000  | female | CA      | 2017-04-28   | 3174         | Condition      | pain in joints on feet                            | 2               |

Fonte: <https://www.kaggle.com/datasets/flaredown/flaredown-autoimmune-symptom-tracker>

# Detalhamento do dataset

## Dados do usuário

- **user\_id:** Um identificador alfanumérico do usuário;
- **age:** Idade do usuário. Possui valores numéricos e *null*;
- **sex:** Dado categórico que representa o sexo do usuário. Pode ser *male*, *female*, *other*, *doesnt\_say* ou *null*;
- **country:** Sigla do país em que o usuário reside. Contém valores *null*;

# Detalhamento do dataset

## Dados do rastreável

- **checkin\_date:** Data de registro do rastreável. YYYY-MM-DD;
- **trackable\_id:** Identificador numérico do rastreável;
- **trackable\_type:** Dado categórico que representa o tipo do rastreável. Pode ser *Condition, Symptom, Treatment, Tag, Food, Weather* ou *HBI*;
- **trackable\_name:** Uma string que representa o nome do rastreável (*Headache* pode ser o trackable\_name de um Symptom, por exemplo). Possui dados inseridos pelo próprio usuário;
- **trackable\_value:** Pode ser a intensidade de um sintoma ou a dosagem de um medicamento, a depender do trackable\_type.

# Tipos de rastreáveis

- **Condition:** uma doença ou diagnóstico, por exemplo, artrite reumatóide, classificado em uma escala de 0 (não ativo) a 4 (extremamente ativo);
- **Symptom:** autoexplicativo, também classificado em uma escala de 0 a 4;
- **Treatment:** qualquer medicamento que um paciente use para melhorar seus sintomas, juntamente com a dosagem, por exemplo “3 x 5mg”;
- **Tag:** um texto que representa um fator ambiental que não ocorre todos os dias, por exemplo, “correu 15 quilômetros” ou “emagreceu 8 quilos”;
- **Food:** os itens alimentares foram sementeados a partir do banco de dados de alimentos do USDA disponível ao público. Os usuários também adicionaram muitos itens alimentares manualmente.

# Detalhamento do dataset

- **Weather:** o clima é puxado automaticamente para o código postal do usuário da API; **Dark Sky.** Os parâmetros climáticos incluem uma descrição, intensidade de precipitação, umidade, pressão e temperaturas mínimas/máximas para o dia.
- **HBI:** o Índice de Harvey Bradshaw é uma métrica específica para avaliar a gravidade da doença de Crohn. Três pontos ou menos no HBI significa propensão à remissão, mas oito ou superior indicam um estado grave.

# Transformações iniciais

Para economizar memória, o atributo **user\_id** é transformado para um valor numérico sequencial.

```
ids = pandas.Categorical(dataset['user_id'])  
dataset["user_id"] = ids.codes
```

|   | user_id | age      | sex    | country | checkin_date | trackable_id | trackable_type | trackable_name                                    | trackable_value |
|---|---------|----------|--------|---------|--------------|--------------|----------------|---------------------------------------------------|-----------------|
| 0 | 9070    | NaN      | NaN    | NaN     | 2015-11-26   | 1069         | Condition      | Ulcerative colitis                                | 0               |
| 1 | 22737   | 32.00000 | male   | US      | 2015-11-26   | 1069         | Condition      | Ulcerative colitis                                | 0               |
| 2 | 376     | 2.00000  | female | CA      | 2017-04-28   | 3168         | Condition      | pain in left upper arm felt like i was getting... | 4               |
| 3 | 376     | 2.00000  | female | CA      | 2017-04-28   | 3169         | Condition      | hip pain when gettin up                           | 3               |
| 4 | 376     | 2.00000  | female | CA      | 2017-04-28   | 3170         | Condition      | pain in hand joints                               | 4               |
| 5 | 376     | 2.00000  | female | CA      | 2017-04-28   | 3171         | Condition      | numbness in right hand                            | 2               |

# Transformações iniciais

O atributo **age** possui *outliers* que estão atrapalhando a estatística desta coluna, como valores negativos e idades que vão além do tempo de vida normal de um ser humano.

```
dataset[(dataset['age'] > 100)].sort_values(by='age',ascending=True).head(10)
```

|     | user_id | age       | sex        | country | checkin_date | trackable_id | trackable_type | trackable_name           | trackable_value |
|-----|---------|-----------|------------|---------|--------------|--------------|----------------|--------------------------|-----------------|
| 598 | 24754   | 118.00000 | doesnt_say | AU      | 2015-08-26   | 220          | Condition      | Chronic fatigue syndrome | 3               |
| 599 | 24754   | 118.00000 | doesnt_say | AU      | 2015-08-26   | 463          | Condition      | Headaches                | 1               |
| 600 | 24754   | 118.00000 | doesnt_say | AU      | 2015-08-26   | 1142         | Condition      | sob                      | 2               |

```
dataset[(dataset['age'] <= 0)].sort_values(by='age',ascending=True).head()
```

|        | user_id | age           | sex  | country | checkin_date | trackable_id | trackable_type | trackable_name   | trackable_value |
|--------|---------|---------------|------|---------|--------------|--------------|----------------|------------------|-----------------|
| 179433 | 24254   | -196691.00000 | male | CA      | 2016-08-02   | 1548         | Symptom        | Trouble Sleeping | 3               |
| 179436 | 24254   | -196691.00000 | male | CA      | 2016-08-02   | 2            | Tag            | stressed         | NaN             |
| 179435 | 24254   | -196691.00000 | male | CA      | 2016-08-02   | 7            | Tag            | had sex          | NaN             |

# Transformações iniciais

Para lidar com estes valores, transformou-se todos os valores menores ou iguais a 0 ou maiores que 117 em NaN.

```
dataset = dataset.assign(age = lambda x: x.age.where(x.age.gt(0)))
```

```
dataset = dataset.assign(age = lambda x: x.age.where(x.age.le(117)))
```

```
count    7666487.00000
mean      35.08054
std       11.71827
min        1.00000
25%       26.00000
50%       34.00000
75%       43.00000
max       99.00000
```

# Análise exploratória




Com o objetivo de explorar e conhecer melhor os dados do nosso dataset, algumas análises foram feitas:

- Categorização por sexo
- Categorização por tipo de rastreável
- Categorização por país
- Categorização por registros de sintomas
- Categorização por registros de tratamentos
- Categorização por registros de condições

# Categorização por sexo


```
dataset_sex_unique = pandas.DataFrame([  
    {'users': dataset[dataset.sex=="doesn't say"].user_id.nunique()},  
    {'users': dataset[dataset.sex=="other"].user_id.nunique()},  
    {'users': dataset[dataset.sex=="male"].user_id.nunique()},  
    {'users': dataset[dataset.sex=="female"].user_id.nunique()}  
], index=['doesn't say', 'other', 'male', 'female'])
```

```
dataset_sex_unique.users.plot(kind='pie')
```



# Categorização por tipo de rastreável

|           |         |
|-----------|---------|
| Symptom   | 3642279 |
| Weather   | 1393806 |
| Condition | 1111517 |
| Treatment | 901820  |
| Food      | 480971  |
| Tag       | 445669  |
| HBI       | 161     |



# Categorização por país




```
unique_countries = dataset.country.unique()
data = []

for country in unique_countries:
    data.append({'users': dataset[dataset.country==country].user_id.nunique()})

dataset_country_unique = pandas.DataFrame(data, index=unique_countries)

plot.figure(figsize=(9,6))
countries = dataset_country_unique.sort_values(by=['users'], ascending=False)['users'].iloc[0:7]
sns.barplot(countries.values, countries.index)
for i, v in enumerate(countries.values):
    plot.text(0.8, i, v, color='k', fontsize=12)
plot.xticks(rotation='vertical')
plot.xlabel('Número de residentes')
plot.ylabel('País')
plot.show()
```

# Categorização por país




# Categorização por registros de sintomas

```
plot.figure(figsize=(9,6))
symptoms = dataset[dataset.trackable_type=="Symptom"].trackable_name.value_counts().iloc[0:15]
sns.barplot(symptoms.values, symptoms.index)
for i, v in enumerate(symptoms.values):
    plot.text(0.8, i, v, color='k', fontsize=12)
plot.xticks(rotation='vertical')
plot.xlabel('Número de registros')
plot.ylabel('Sintoma')
plot.show()
```

Quantidade de registros únicos:

23.157




# Categorização por registros de tratamentos

```
plot.figure(figsize=(9,6))
treatments = dataset[dataset.trackable_type=="Treatment"].trackable_name.value_counts().iloc[0:10]
sns.barplot(treatments.values, treatments.index)
for i, v in enumerate(treatments.values):
    plot.text(0.8, i, v, color='k', fontsize=12)
plot.xticks(rotation='vertical')
plot.xlabel('Número de registros')
plot.ylabel('Tratamento')
plot.show()
```

Quantidade de registros únicos:

8.155




# Categorização por registros de condições

```
plot.figure(figsize=(9,6))
conditions = dataset[dataset.trackable_type=="Condition"].trackable_name.value_counts().iloc[0:10]
sns.barplot(conditions.values, conditions.index)
for i, v in enumerate(conditions.values):
    plot.text(0.8, i, v, color='k', fontsize=12)
plot.xticks(rotation='vertical')
plot.xlabel('Número de registros')
plot.ylabel('Condição')
plot.show()
```

Quantidade de registros únicos:

9.443



# Associação - transformação

- Precisamos transformar o *dataframe* original em uma matriz de valores booleanos para aplicar o algoritmo Apriori;
- Agrupar por ID do usuário e data do *trackable*;

| user_id                          | checkin_date | trackable_id | trackable_type | trackable_name | trackable_value |
|----------------------------------|--------------|--------------|----------------|----------------|-----------------|
| QEVuQwEAO+R1md5HUn8+w1Qpbg7ogw== | 26/05/2017   | 152          | Symptom        | Nausea         | 1               |
| QEVuQwEAO+R1md5HUn8+w1Qpbg7ogw== | 26/05/2017   | 9890         | Treatment      | Zofran         | 8.0 mg          |
| QEVuQwEAO+R1md5HUn8+w1Qpbg7ogw== | 27/05/2017   | 152          | Symptom        | Nausea         | 2               |
| QEVuQwEAO+R1md5HUn8+w1Qpbg7ogw== | 27/05/2017   | 8            | Symptom        | Anxiety        | 2               |
| QEVuQwEAO+R1md5HUn8+w1Qpbg7ogw== | 27/05/2017   | 242          | Symptom        | Fatigue        | 1               |

| symptom_nausea | symptom_anxiety | symptom_fatigue | treatment_zofran |
|----------------|-----------------|-----------------|------------------|
| TRUE           | FALSE           | FALSE           | TRUE             |
| TRUE           | TRUE            | TRUE            | FALSE            |

# Associação - pré-processamento

- Transformamos todos os valores das colunas *trackable\_type* e *trackable\_name* para lowercase;

```
# Pré-processa o dataframe original
dfOrigin = pandas.DataFrame.copy(dataset)
dfOrigin['trackable_type'] = dfOrigin['trackable_type'].str.lower()
dfOrigin['trackable_name'] = dfOrigin['trackable_name'].str.lower()
```

# Associação - seleção

- Selecionar os primeiros **15** valores de sintomas mais frequentes;
- Selecionar os primeiros **15** valores de tratamentos mais frequentes;
- Após, selecionar os primeiros **100.000** registros que são sintomas e possuem um sintoma frequente ou são tratamentos e possuem um tratamento frequente:

```
# Conta as frequências dos sintomas e tratamentos, pega somente os mais frequentes para escolher os registros e as colunas
dfFrequentSymptoms = dfOrigin[dfOrigin['trackable_type'] == 'symptom']['trackable_name'].value_counts().head(MAX_SYMPTOM_COLUMNS)
dfFrequentTreatments = dfOrigin[dfOrigin['trackable_type'] == 'treatment']['trackable_name'].value_counts().head(MAX_TREATMENT_COLUMNS)

# Pega registros que possuem sintoma frequente ou tratamento frequente
dfOrigin = dfOrigin[
    ((dfOrigin['trackable_type'] == 'symptom') & (dfOrigin['trackable_name'].isin(dfFrequentSymptoms['trackable_name'].tolist()))) |
    ((dfOrigin['trackable_type'] == 'treatment') & (dfOrigin['trackable_name'].isin(dfFrequentTreatments['trackable_name'].tolist())))
]

dfOrigin = dfOrigin.head(MAX_ROWS)
```

# Associação - seleção

```
# Cria as colunas do dataframe final
dfFinal = pandas.DataFrame({})

symptomColumnNames = ['symptom_' + s for s in dfFrequentSymptoms['trackable_name'].unique()]
treatmentColumnNames = ['treatment_' + t for t in dfFrequentTreatments['trackable_name'].unique()]

for symptomColumn in symptomColumnNames:
    dfFinal.insert(dfFinal.columns.size, symptomColumn, [])

for treatmentColumn in treatmentColumnNames:
    dfFinal.insert(dfFinal.columns.size, treatmentColumn, [])
```

# Associação - seleção

```
# Cria as linhas do dataframe final
for name, group in groupedDf:
    newRow = pandas.DataFrame({})

    for column in dfFinal.columns:
        newRow.at[0, column] = False

    for index, row in group.iterrows():
        columnName = row['trackable_type'] + "_" + row['trackable_name']
        newRow.at[0, columnName] = True

dfFinal = pandas.concat([dfFinal, newRow], ignore_index = True)
```

# Associação - resultado da seleção

|       | symptom_headache | symptom_fatigue | symptom_nausea | symptom_brain fog | symptom_joint pain | symptom_fatigue and tiredness | symptom_anxiety | ... |
|-------|------------------|-----------------|----------------|-------------------|--------------------|-------------------------------|-----------------|-----|
| 0     | True             | False           | False          | False             | False              | False                         | False           |     |
| 1     | True             | False           | False          | False             | False              | False                         | False           |     |
| 2     | False            | True            | True           | False             | False              | False                         | False           |     |
| 3     | True             | False           | False          | False             | False              | False                         | True            |     |
| 4     | True             | False           | True           | False             | False              | False                         | False           |     |
| ...   | ...              | ...             | ...            | ...               | ...                | ...                           | ...             |     |
| 29397 | False            | False           | False          | False             | False              | False                         | False           |     |
| 29398 | False            | False           | False          | False             | False              | False                         | False           |     |
| 29399 | False            | True            | False          | False             | False              | False                         | False           |     |
| 29400 | False            | False           | False          | False             | True               | False                         | False           |     |
| 29401 | True             | False           | False          | True              | False              | True                          | False           |     |

# Associação - Apriori

- Começamos com um suporte mínimo de 5% e uma confiança mínima de 50%;

```
# Aplicando algoritmo Apriori
rules = apriori(dfFinal, min_support = 0.05, use_colnames = True)
associationRules = association_rules(rules, metric = "confidence", min_threshold = 0.5)
```

# Associação - resultados

- Nenhum tratamento presente nas regras de associação;
- Maioria das regras contém sintomas genéricos, como dor de cabeça e fadiga;

|    | antecedents                            | consequents        | antecedent support | consequent support | support | confidence | lift    | leverage | conviction |
|----|----------------------------------------|--------------------|--------------------|--------------------|---------|------------|---------|----------|------------|
| 0  | (symptom_nausea)                       | (symptom_headache) | 0.28318            | 0.38355            | 0.16169 | 0.57098    | 1.48870 | 0.05308  | 1.43690    |
| 1  | (symptom_dizziness)                    | (symptom_headache) | 0.17679            | 0.38355            | 0.11057 | 0.62543    | 1.63066 | 0.04276  | 1.64578    |
| 2  | (symptom_back pain)                    | (symptom_headache) | 0.15094            | 0.38355            | 0.08244 | 0.54619    | 1.42406 | 0.02455  | 1.35840    |
| 3  | (symptom_neck pain)                    | (symptom_headache) | 0.13751            | 0.38355            | 0.08605 | 0.62577    | 1.63155 | 0.03331  | 1.64727    |
| 4  | (symptom_brain fog)                    | (symptom_fatigue)  | 0.18094            | 0.37028            | 0.11169 | 0.61729    | 1.66709 | 0.04469  | 1.64543    |
| 5  | (symptom_migraine)                     | (symptom_fatigue)  | 0.09265            | 0.37028            | 0.05088 | 0.54919    | 1.48318 | 0.01658  | 1.39687    |
| 6  | (symptom_dizziness)                    | (symptom_nausea)   | 0.17679            | 0.28318            | 0.09309 | 0.52655    | 1.85943 | 0.04303  | 1.51404    |
| 7  | (symptom_abdominal pain)               | (symptom_nausea)   | 0.13564            | 0.28318            | 0.06809 | 0.50201    | 1.77276 | 0.02968  | 1.43942    |
| 8  | (symptom_depression)                   | (symptom_anxiety)  | 0.16591            | 0.21594            | 0.10132 | 0.61070    | 2.82814 | 0.06549  | 2.01404    |
| 9  | (symptom_constipation)                 | (symptom_diarrhea) | 0.14064            | 0.20366            | 0.09397 | 0.66820    | 3.28096 | 0.06533  | 2.40005    |
| 10 | (symptom_nausea, symptom_fatigue)      | (symptom_headache) | 0.11384            | 0.38355            | 0.06687 | 0.58739    | 1.53148 | 0.02321  | 1.49404    |
| 11 | (symptom_nausea, symptom_joint pain)   | (symptom_headache) | 0.09731            | 0.38355            | 0.06765 | 0.69521    | 1.81259 | 0.03033  | 2.02257    |
| 12 | (symptom_joint pain, symptom_headache) | (symptom_nausea)   | 0.12353            | 0.28318            | 0.06765 | 0.54763    | 1.93388 | 0.03267  | 1.58460    |
| 13 | (symptom_nausea, symptom_dizziness)    | (symptom_headache) | 0.09309            | 0.38355            | 0.07003 | 0.75228    | 1.96139 | 0.03433  | 2.48855    |
| 14 | (symptom_dizziness, symptom_headache)  | (symptom_nausea)   | 0.11057            | 0.28318            | 0.07003 | 0.63334    | 2.23656 | 0.03872  | 1.95502    |
| 15 | (symptom_nausea, symptom_neck pain)    | (symptom_headache) | 0.06523            | 0.38355            | 0.05098 | 0.78154    | 2.03768 | 0.02596  | 2.82186    |
| 16 | (symptom neck pain, symptom headache)  | (symptom nausea)   | 0.08605            | 0.28318            | 0.05098 | 0.59249    | 2.09229 | 0.02662  | 1.75903    |

# Associação - resultados

- Algumas regras interessantes:

|    | antecedents                            | consequents        | antecedent support | consequent support | support | confidence | lift    | leverage | conviction |
|----|----------------------------------------|--------------------|--------------------|--------------------|---------|------------|---------|----------|------------|
| 0  | (symptom_nausea)                       | (symptom_headache) | 0.28318            | 0.38355            | 0.16169 | 0.57098    | 1.48870 | 0.05308  | 1.43690    |
| 1  | (symptom_dizziness)                    | (symptom_headache) | 0.17679            | 0.38355            | 0.11057 | 0.62543    | 1.63066 | 0.04276  | 1.64578    |
| 2  | (symptom_back pain)                    | (symptom_headache) | 0.15094            | 0.38355            | 0.08244 | 0.54619    | 1.42406 | 0.02455  | 1.35840    |
| 3  | (symptom_neck pain)                    | (symptom_headache) | 0.13751            | 0.38355            | 0.08605 | 0.62577    | 1.63155 | 0.03331  | 1.64727    |
| 4  | (symptom_brain fog)                    | (symptom_fatigue)  | 0.18094            | 0.37028            | 0.11169 | 0.61729    | 1.66709 | 0.04469  | 1.64543    |
| 5  | (symptom_migraine)                     | (symptom_fatigue)  | 0.09265            | 0.37028            | 0.05088 | 0.54919    | 1.48318 | 0.01658  | 1.39687    |
| 6  | (symptom_dizziness)                    | (symptom_nausea)   | 0.17679            | 0.28318            | 0.09309 | 0.52655    | 1.85943 | 0.04303  | 1.51404    |
| 7  | (symptom_abdominal pain)               | (symptom_nausea)   | 0.13564            | 0.28318            | 0.06809 | 0.50201    | 1.77276 | 0.02968  | 1.43942    |
| 8  | (symptom_depression)                   | (symptom_anxiety)  | 0.16591            | 0.21594            | 0.10132 | 0.61070    | 2.82814 | 0.06549  | 2.01404    |
| 9  | (symptom_constipation)                 | (symptom_diarrhea) | 0.14064            | 0.20366            | 0.09397 | 0.66820    | 3.28096 | 0.06533  | 2.40005    |
| 10 | (symptom_nausea, symptom_fatigue)      | (symptom_headache) | 0.11384            | 0.38355            | 0.06687 | 0.58739    | 1.53148 | 0.02321  | 1.49404    |
| 11 | (symptom_nausea, symptom_joint pain)   | (symptom_headache) | 0.09731            | 0.38355            | 0.06765 | 0.69521    | 1.81259 | 0.03033  | 2.02257    |
| 12 | (symptom_joint pain, symptom_headache) | (symptom_nausea)   | 0.12353            | 0.28318            | 0.06765 | 0.54763    | 1.93388 | 0.03267  | 1.58460    |
| 13 | (symptom_nausea, symptom_dizziness)    | (symptom_headache) | 0.09309            | 0.38355            | 0.07003 | 0.75228    | 1.96139 | 0.03433  | 2.48855    |
| 14 | (symptom_dizziness, symptom_headache)  | (symptom_nausea)   | 0.11057            | 0.28318            | 0.07003 | 0.63334    | 2.23656 | 0.03872  | 1.95502    |
| 15 | (symptom_nausea, symptom_neck pain)    | (symptom_headache) | 0.06523            | 0.38355            | 0.05098 | 0.78154    | 2.03768 | 0.02596  | 2.82186    |
| 16 | (symptom_neck pain, symptom_headache)  | (symptom_nausea)   | 0.08605            | 0.28318            | 0.05098 | 0.59249    | 2.09229 | 0.02662  | 1.75903    |

# Associação (2) - resultados

- Segunda tentativa: Tentar encontrar associações entre tratamentos;
- Selecionar apenas tratamentos (15 mais usados);
- 0.5% suporte;
- 45% de confiança;

```
# Aplicando algoritmo Apriori
rules = apriori(dfFinal, min_support = 0.005, use_colnames = True)
associationRules = association_rules(rules, metric = "confidence", min_threshold = 0.45)
```

|   | antecedents                                      | consequents               | antecedent support | consequent support | support | confidence | lift    | leverage | conviction |
|---|--------------------------------------------------|---------------------------|--------------------|--------------------|---------|------------|---------|----------|------------|
| 0 | (treatment_naproxen, treatment_magnesium)        | (treatment_ibuprofen)     | 0.00881            | 0.24261            | 0.00545 | 0.61849    | 2.54934 | 0.00331  | 1.98524    |
| 1 | (treatment_naproxen, treatment_paracetamol)      | (treatment_ibuprofen)     | 0.01281            | 0.24261            | 0.00561 | 0.43815    | 1.80601 | 0.00250  | 1.34803    |
| 2 | (treatment_paracetamol, treatment_omeprazole)    | (treatment_amitriptyline) | 0.01386            | 0.08517            | 0.00644 | 0.46474    | 5.45645 | 0.00526  | 1.70914    |
| 3 | (treatment_paracetamol, treatment_amitriptyline) | (treatment_omeprazole)    | 0.01410            | 0.07981            | 0.00644 | 0.45693    | 5.72505 | 0.00532  | 1.69443    |
| 4 | (treatment_omeprazole, treatment_amitriptyline)  | (treatment_paracetamol)   | 0.01359            | 0.12955            | 0.00644 | 0.47386    | 3.65767 | 0.00468  | 1.65439    |

# Associação (3) - resultados

- Terceira tentativa: **200.000** registros;
- Selecionar apenas tratamentos (20 mais usados);
- 1% suporte;
- 60% de confiança;

```
# Aplicando algoritmo Apriori
rules = apriori(dfFinal, min_support = 0.01, use_colnames = True)
associationRules = association_rules(rules, metric = "confidence", min_threshold = 0.6)
```

|   | antecedents                                   | consequents              | antecedent support | consequent support | support | confidence | lift     | leverage | conviction |
|---|-----------------------------------------------|--------------------------|--------------------|--------------------|---------|------------|----------|----------|------------|
| 0 | (treatment_probiotic, treatment_vitamin d)    | (treatment_multivitamin) | 0.01671            | 0.07180            | 0.01168 | 0.69919    | 9.73823  | 0.01048  | 3.08569    |
| 1 | (treatment_probiotic, treatment_multivitamin) | (treatment_vitamin d)    | 0.01631            | 0.09518            | 0.01168 | 0.71614    | 7.52373  | 0.01013  | 3.18759    |
| 2 | (treatment_vitamin d, treatment_multivitamin) | (treatment_probiotic)    | 0.01750            | 0.06583            | 0.01168 | 0.66759    | 10.14157 | 0.01053  | 2.81027    |

# Referências



FLAREDOWN. **Chronic illness: symptoms, treatments and triggers**. 2022. Disponível em: <<https://www.kaggle.com/datasets/flaredown/flaredown-autoimmune-symptom-tracker>>. Acesso em: 6 ago. 2022.

PANDAS DOCUMENTATION. **Plotting with matplotlib**. 2022. Disponível em: <<https://pandas.pydata.org/pandas-docs/version/0.13/visualization.html>>. Acesso em: 3 set. 2022.

SEABORN DOCUMENTATION. **An introduction to seaborn**. 2022. Disponível em: <<https://seaborn.pydata.org/introduction.html>>. Acesso em: 3 set. 2022.



**UNIVALI**

Universidade do Vale do Itajaí  
Escola do Mar, Ciência e Tecnologia - EMCT  
Ciência da Computação

---

# **PROCESSO DE KDD APLICADO EM SINTOMAS DE DOENÇAS CRÔNICAS**

---

Caio Gonzaga Bernils  
Gustavo Henrique Stahl Müller  
Paulo Henrique Rohling

---

